

- 1) (1,0 ponto) - Considere uma amostra que possui 12 trabalhadores e que revelou os seguintes salários recebidos por um mês de trabalho na empresa xyz: R\$ 1.518,00, R\$ 1.850,00, R\$ 1.752,00, R\$ 1.850,00, R\$ 2.500,00, R\$ 2.000,00, R\$ 3450,00, R\$ 12.000,00, R\$ 3.050,00, R\$ 4.400,00, R\$ 5.154,25, R\$ 6.247,00. Deste modo, elabore um gráfico Box Plot, informando os valores mínimo, primeiro quartil, segundo quartil, terceiro quartil e o valor máximo. Existem outliers na distribuição apresentada?

**Passo 1 – Ordenar os dados**

1.518,00, 1.752,00, 1.850,00, 1.850,00, 2.000,00, 2.500,00, 3.050,00, 3.450,00, 4.400,00, 5.154,25, 6.247,00, 12.000,00

**Passo 2 – Calcular a Mediana (Segundo Quartil – Q2)**

A mediana é o valor central que divide o conjunto de dados em duas metades. Como temos 12 observações (um número par), a mediana será a média dos dois valores centrais (o 6º e o 7º).

$$Q2 = \frac{2500,00 + 3050,00}{2}$$

$$Q2 = 2.775,00$$

**Passo 3 – Calcular o Primeiro Quartil – Q1**

O primeiro quartil é a mediana da metade inferior dos dados. A metade inferior é composta pelos 6 primeiros valores.

Metade inferior = 1.518,00, 1.752,00, 1.850,00, 1.850,00, 2.000,00, 2.500,00

A metade inferior dos dados possui 6 elementos, logo a mediana corresponde a média dos dois valores centrais (3º e 4º)

$$Q1 = \frac{1850,00 + 1850,00}{2}$$

$$Q1 = 1.850,00$$

**Passo 4 – Calcular o Terceiro Quartil – Q3**

O terceiro quartil é a mediana da metade superior dos dados. A metade superior é composta pelos 6 últimos valores.

Metade superior = 3.050,00, 3.450,00, 4.400,00, 5.154,25, 6.247,00, 12.000,00

A metade superior dos dados possui 6 elementos, logo a mediana corresponde a média dos dois valores centrais (3º e 4º)

$$Q3 = \frac{4400,00 + 5154,25}{2}$$

$$Q3 = 4.777,13$$

### **Passo 5 – Amplitude Interquartil**

A amplitude interquartil corresponde a diferença entre o terceiro e o primeiro quartil. Ela representa a faixa de valores onde se encontram os 50% centrais dos dados.

$$AIQ = Q3 - Q1$$

$$AIQ = 4.777,13 - 1.850,00$$

$$AIQ = 2.927,13$$

Passo 6 - Cálculo dos valores máximo e mínimo (Limites do Box Plot)

Os valores máximo e mínimo no diagrama de caixa são utilizados para identificar outliers.


1. Valor mínimo (absoluto): É o menor valor da amostra (R\$ 1.518,00).
2. Valor máximo (absoluto): É o maior valor da amostra (R\$ 12.000,00)

**Límite superior:**  $Q3 + 1,5 \cdot AIQ = 4.777,13 + 1,5 \cdot 2.927,13 = 9.167,83$

**Límite inferior:**  $Q1 - 1,5 \cdot AIQ = 1.850,00 - 1,5 \cdot 2.927,13 = 1.850,00 - 4.390,69 = -2.540,69$

O "máximo" da haste do gráfico será o maior valor da amostra que seja **menor ou igual a R\$ 9.167,83**. Neste caso, é o **R\$ 6.247,00**. O valor de R\$ 12.000,00 está acima deste limite e é considerado um **outlier**.

O "mínimo" da haste será o menor valor da amostra que seja **maior ou igual a R\$ -2.540,69**. Neste caso, é o próprio **R\$ 1.518,00**.



- 2) (0,75 pontos) - A passagem de 11 veículos por um radar eletrônico, em uma rodovia, registrou as velocidades apresentadas abaixo (em km/h).

53	45	46	49	46	77	54	48	41	46	56
----	----	----	----	----	----	----	----	----	----	----

- a) Determine sua média, desvio padrão e o coeficiente de variação.

A média é dada pela fórmula abaixo:

$$\mu = \frac{\sum_{i=1}^N x_i}{N}$$

$$\mu = \frac{53 + 45 + 46 + 49 + 46 + 77 + 54 + 48 + 41 + 46 + 56}{11} = \frac{561}{11} = 51$$

A média de velocidade é de 51 km/h.

A variância é dada pela fórmula abaixo, considera-se a fórmula da população e não da amostra:

$$\sigma^2 = \frac{\left( \sum_{i=1}^N x_i - \mu \right)^2}{N}$$

Cálculo do quadrado das diferenças:

$$\begin{aligned}(53-51)^2 &= 2^2 = 4 \\ (45-51)^2 &= (-6)^2 = 36 \\ (46-51)^2 &= (-5)^2 = 25 \\ (49-51)^2 &= (-2)^2 = 4 \\ (46-51)^2 &= (-5)^2 = 25 \\ (77-51)^2 &= 26^2 = 676 \\ (54-51)^2 &= 3^2 = 9 \\ (48-51)^2 &= (-3)^2 = 9 \\ (41-51)^2 &= (-10)^2 = 100 \\ (46-51)^2 &= (-5)^2 = 25 \\ (56-51)^2 &= 5^2 = 25\end{aligned}$$

Deste modo tem-se:

$$\sigma^2 = \frac{938}{11} = 85,27$$

O desvio padrão é a raiz quadrada da variância, conforme apresentado abaixo:

$$\sigma = \sqrt{\frac{\left( \sum_{i=1}^N x_i - \mu \right)^2}{N}}$$

Portanto, o valor do desvio padrão é igual a:

$$\begin{aligned}\sigma &= \sqrt{85,27} \\ \sigma &= 9,23\end{aligned}$$

O cálculo do coeficiente de variação é dado pela fórmula abaixo:

$$CV = \left( \frac{\sigma}{\mu} \right) \cdot 100\%$$

Dado que temos os valores do desvio padrão e da média, obtém-se:

$$CV = \left( \frac{9,23}{51} \right) \cdot 100\% = 18,1\%$$

- b) **Se este radar eletrônico foi regulado dando um desconto de 5 km/h nas velocidades dos veículos, qual é a verdadeira média?**

A questão afirma que o radar eletrônico foi regulado para ter um “desconto” de 5 km/h. Portanto, isso nos diz que a velocidade registrada é 5 km/h menor que a velocidade real do veículo.

$$\text{Velocidade registrada} = \text{Velocidade verdadeira} - 5 \text{ km/h}$$

Deste modo, para obter-se a velocidade verdadeira é necessário somar 5 km/h a cada velocidade registrada.

Uma propriedade da média é que, se somarmos uma constante a todos os valores de um conjunto de dados, a nova média será a média original somada a essa constante.

$$\text{Média verdadeira} = \text{Média registrada} + 5 \text{ km/h}$$

$$\mu_{\text{verdadeira}} = 51 + 5 = 56$$

- 3) **(0,75 pontos) - Em uma caixa há 6 bolas vermelhas, 4 bolas azuis e 2 bolas verdes. Se você retirar duas bolas da caixa, uma após a outra e sem reposição, qual a probabilidade de a primeira bola ser azul e a segunda ser vermelha?**

Este é um problema trabalha com probabilidade condicional, dado que a retirada da primeira bola afeta o total de bolas disponíveis para a segunda retirada.

**I. Calcular total de bolas:**

$$\text{Total} = 6 \text{ (vermelhas)} + 4 \text{ (azuis)} + 2 \text{ (verdes)} = 12 \text{ bolas.}$$

**II. Probabilidade do 1º evento:**

A probabilidade de a primeira bola retirada ser azul é o número de bolas azuis dividido pelo total de bolas.

$$P(1^{\text{a}} \text{ Ser Azul}) = \frac{\text{Número De Bolas Azuis}}{\text{Total De Bolas}} = \frac{4}{12}$$

**III. Probabilidade do segundo evento (dado que o primeiro já ocorreu):**

Após retirar uma bola azul (**sem reposição**), a caixa agora tem um total de 11 bolas.

O número de bolas vermelhas permanece o mesmo (6).

A probabilidade de a segunda bola ser vermelha, *dado que a primeira foi azul*, é:

$$P(2^{\text{a}} \text{ SerVermelha} \mid 1^{\text{a}} \text{ FoiAzul}) \frac{\text{NúmeroDeBolasVermelhas}}{\text{TotalDeBolas}} = \frac{6}{11}$$

IV. Cálculo da probabilidade total:

Para encontrar a probabilidade de ambos os eventos ocorrerem em sequência, multiplicamos a probabilidade do primeiro evento pela probabilidade do segundo.

$$\begin{aligned} P &= \frac{4}{12} \cdot \frac{6}{11} \\ P &= \frac{24}{132} \end{aligned}$$

Realizando a simplificação da fração acima, obtém-se:

$$P = \frac{2}{11}$$

- 4) **(0,50 pontos)** - Uma planilha Excel foi importada para o software Rstudio, armazenando dados de clientes em um data frame chamado **dados**. Abaixo é apresentado o data frame.

Nome	Categoria	Idade	Vendas_Total	Vendas_Ultimo_Mes	Ativo
Ana	A	28	150.50	50.00	Sim
Bruno	B	35	220.00		Sim
Carla	A	42	95.75	0.00	Não
Daniel	C	22	310.20	120.50	Sim
Eduarda	B	39	180.00	95.00	Sim
Fábio	A	51		75.00	Não

Analise as afirmações a seguir:

- I. O comando `dados$Idade > 40` gerará um vetor lógico (TRUE/FALSE) que conterá exatamente dois valores TRUE.
- II. A expressão `sum(dados$Vendas_Ultimo_Mes < 10)` retornará o valor 1, referente à linha de Carla, pois comparações com NA (o valor de Bruno) são tratadas como FALSE.
- III. O comando `subset(dados, Ativo == "Sim" & Vendas_Total > 300)` retornará um data frame contendo apenas a linha de Daniel.
- IV. O comando `dados$status_Vendas <- ifelse(dados$Vendas_Total > 200, "Alto", "Baixo")` criará uma nova coluna onde o valor para a linha de Fábio será "Baixo".
- V. O comando `mean(dados$Vendas_Total)` retornará o valor NA. Para calcular a média ignorando os valores ausentes, o comando correto seria `mean(dados$Vendas_Total, na.rm = TRUE)`.

As alternativas incorretas são:

- a) I, II e III
- b) III, IV e V
- c) II, III e IV
- d) II e IV
- e) IV e V

#### I – Verdadeira

Justificativa: A expressão `dados$Idade > 40` realiza uma comparação elemento por elemento na coluna Idade. Ao verificar os valores `c(28, 35, 42, 22, 39, 51)`, verifica-se que Carla (42) e Fábio (51) são os únicos com idade maior que 40. Portanto, o vetor lógico resultante terá exatamente dois “valores” TRUE.

#### II – Falsa

Qualquer operação de comparação com NA, resulta em NA, não em FALSE. O vetor lógico da comparação será `c(FALSE, NA, TRUE, FALSE, FALSE, FALSE)`. Como a função `sum()` por padrão não remove valores NA (`na.rm = FALSE`), a soma de um vetor que contém NA também resulta em NA, e não no número 1.

#### III – Verdadeira

A função `subset` filtra os dados com base nas condições fornecidas. A condição `Ativo == "Sim"` seleciona as linhas 1, 2, 4 e 5. Dessas linhas, a condição `Vendas_Total > 300` é aplicada, e apenas a linha 4 (Daniel, como vendas de 310,20) satisfaz o critério. O resultado é um data frame com a linha de Daniel.

#### IV – Falsa

A função `ifelse(teste, valor_sim, valor_não)` avalia a condição teste. Para a linha de Fábio, o teste é `NA > 200`, que resulta em NA. A função `ifelse` propaga o NA do teste para o resultado. Deste modo, o valor na nova coluna `Status_Vendas` para Fábio será NA, e não “Baixo”.

#### V - Verdadeira

Por padrão, funções como `mean()`, `sum()`, `max()`, etc., retornam NA se houver qualquer valor NA nos dados. Para informar a função que deve ser ignorado tais valores ausentes antes de fazer o cálculo, o argumento `na.rm = TRUE` deve ser utilizado.

- 5) **(0,50 pontos)** - Na estatística as representações gráficas são ferramentas indispensáveis para visualização e interpretação de dados. Existem diferentes tipos de gráficos para sintetizar os dados, são eles: gráficos de barras, histograma, gráficos de linhas, setor e BoxPlot. Um aluno durante a aula de estatística recebeu 4 séries estatísticas de dados para analisar, são elas:

- S1: Evolução do consumo mensal de materiais;
- S2: Participação percentual de cada sócio no capital de uma empresa;
- S3: Quantidade de alunos de uma escola por faixa etária;
- S4: Comparação de distribuição das notas obtidas por três turmas diferentes (A, B e C) em uma mesma prova.

O tipo de gráfico mais adequado para representar essas séries, são:

- a) S1: Gráfico de Linhas; S2: Gráfico de Setores; S3: BoxPlot; S4: Histograma.
- b) S1: Gráfico de Linhas; S2: BoxPlot; S3: Histograma; S4: Gráfico de Barras.
- c) S1: Gráfico de Linhas; S2: Gráfico de Barras; S3: Histograma; S4: Gráfico de Barras.
- d) S1: Gráfico de Linhas; S2: Gráfico de Setores; S3: Histograma; S4: BoxPlot.**
- e) S1: Gráfico de Barras; S2: Gráfico de Setores; S3: Gráfico de Linhas; S4: Histograma.

- **S1: Gráfico de Linhas:** Perfeito para "Evolução do consumo mensal". Gráficos de linha são a ferramenta padrão para mostrar a tendência de uma variável contínua ao longo do tempo.
- **S2: Gráfico de Setores:** Ideal para "Participação percentual". Este tipo de gráfico, também conhecido como gráfico de pizza, é projetado especificamente para ilustrar as proporções de diferentes categorias como partes de um todo (100% do capital da empresa).
- **S3: Histograma:** A escolha exata para "Quantidade de alunos por faixa etária". Um histograma representa a distribuição de frequência de uma variável numérica contínua (idade) que foi dividida em intervalos (as faixas etárias).
- **S4: BoxPlot:** A melhor opção para "Comparação de distribuição das notas". O BoxPlot é superior a outras ferramentas para comparar a distribuição de uma variável numérica (notas) entre diferentes grupos (as turmas), mostrando a mediana, a dispersão (intervalo interquartil) e possíveis outliers de cada turma lado a lado.



- 6) **(0,2 pontos)** - Ao nascerem, os bebês são avaliados em diversas frentes para verificar seu estado de saúde. Considere as seguintes variáveis anotadas na ficha

de um recém-nascido: o peso em quilogramas (kg), a altura em centímetros (cm), o sexo e a nota do teste Apgar (um valor inteiro de 0 a 10).

A classificação correta para estas quatro variáveis, respectivamente, é:

- I. Contínua, Contínua, Qualitativa Nominal e Quantitativa Discreta.
- II. Contínua, Contínua, Qualitativa Ordinal e Quantitativa Contínua.
- III. Discreta, Discreta, Qualitativa Nominal e Quantitativa Discreta.
- IV. Contínua, Discreta, Qualitativa Nominal e Quantitativa Discreta.
- V. Ambas quantitativas contínuas, e ambas qualitativas nominais.

#### 1. Peso (em quilogramas)

- **Tipo:** Quantitativa Contínua.
- **Justificativa:** O peso é uma variável que resulta de uma **medição**. Ele pode assumir qualquer valor dentro de um intervalo, incluindo frações e decimais (ex: 3,450 kg, 2,985 kg). A precisão do valor é limitada apenas pela acurácia da balança. Por ser um número obtido por medição, é classificada como **contínua**.

#### 2. Altura (em centímetros)

- **Tipo:** Quantitativa Contínua.
- **Justificativa:** Assim como o peso, a altura (ou comprimento) de um bebê é obtida através de uma **medição**. Ela também pode assumir qualquer valor em uma escala, como 49,5 cm ou 50,2 cm. Portanto, é uma variável **contínua**.


#### 3. Sexo

- **Tipo:** Qualitativa Nominal.
- **Justificativa:** Esta variável descreve uma qualidade ou categoria ("Masculino" ou "Feminino"). Não existe uma ordem ou hierarquia natural entre essas categorias (nenhuma é intrinsecamente "maior" ou "menor" que a outra). Por se tratar de categorias sem uma ordem, é classificada como **nominal**.

#### 4. Nota do Teste Apgar

- **Tipo:** Quantitativa Discreta.
- **Justificativa:** A nota Apgar é um valor numérico que resulta de uma **contagem** ou soma de pontos (de 0 a 10). Um bebê pode receber uma nota 7 ou 8, mas nunca uma nota 7,5. Como os valores possíveis são apenas números inteiros e específicos, resultantes de uma contagem, a variável é classificada como **discreta**.

- 7) Em uma pesquisa de opinião, feita para verificar o nível de aprovação de um governante, foram entrevistadas 1.000 pessoas, que responderam sobre a administração da cidade X, escolhendo uma, e apenas uma, dentre as possíveis respostas: Ótimo, Bom, Regular, Ruim e Indiferente. O gráfico abaixo, apresenta o resultado da pesquisa.



De acordo com o gráfico, pode-se afirmar que o percentual de pessoas que consideram a administração ótima, boa ou regular é igual a:

- a) 56%
- b) 84%**
- c) 80%
- d) 64%
- e) 78%

**8)** Em uma universidade com 2000 estudantes, foi realizada uma pesquisa sobre a participação em atividades extracurriculares. Os dados coletados são os seguintes:

- 800 estudantes participam de alguma equipe esportiva (Evento E);
- 600 estudantes são membros de clubes acadêmicos (Evento C);
- 240 estudantes participam tanto de equipes esportivas quanto de clubes acadêmicos (Evento  $E \cap C$ ).

Com base nessas informações, analise as seguintes afirmações e classifique-as como **Verdadeira (V)** ou **Falsa (F)**, justificando cada resposta com os cálculos apropriados.

1. A probabilidade de um estudante, selecionado aleatoriamente, ser membro de um clube acadêmico é de 0,4;
2. Os eventos "participar de uma equipe esportiva" e "ser membro de um clube acadêmico" são eventos independentes;
3. A probabilidade de um estudante ser membro de um clube acadêmico, dado que ele já participa de uma equipe esportiva, é de 0,3.

**Afirmativa 1: INCORRETA**

probabilidade de um estudante, selecionado aleatoriamente, ser membro de um clube acadêmico é de 0,4;

Está afirmação testa o cálculo básico da probabilidade de um evento.

A probabilidade de um estudante ser membro de um clube acadêmico é:

$$P(C) = \frac{\text{NúmeroDeMembrosDeClubes}}{\text{TotalDeEstudantes}} = \frac{600}{2000} = 0,3$$

### Afirmativa 2: CORRETA

Os eventos "participar de uma equipe esportiva" e "ser membro de um clube acadêmico" são eventos independentes;

Para que dois eventos, E e C, sejam independentes, a probabilidade de ambos ocorrerem deve ser igual ao produto de suas probabilidades individuais. A condição de independência é:

$$P(E \cap C) = P(E) \cdot P(C)$$

A probabilidade de participar de uma equipe esportiva ( $P(E)$ ) é igual a:

$$P(E) = \frac{\text{NúmeroDeAtletas}}{\text{TotalDeEstudantes}} = \frac{800}{2000} = 0,4$$

Deste modo, tem-se que:

$$P(E \cap C) = P(E) \cdot P(C)$$

$$P(E \cap C) = 0,4 \cdot 0,3$$

$$P(E \cap C) = 0,12$$

Os eventos são, por definição, independentes. A participação em esportes não afeta a probabilidade de um estudante participar de um clube acadêmico, e vice-versa.

### Afirmativa 3: CORRETA

A probabilidade de um estudante ser membro de um clube acadêmico, dado que ele já participa de uma equipe esportiva, é de 0,3.

Esta afirmação envolve o conceito de probabilidade condicional. Queremos encontrar a probabilidade do evento C, sabendo que o evento E já ocorreu, ou seja,  $P(C|E)$ .

A fórmula da probabilidade condicional é:

$$P(C|E) = \frac{P(E \cap C)}{P(E)}$$

$$P(C|E) = \frac{0,12}{0,4} = 0,3$$

O resultado do cálculo corresponde ao valor da afirmação.